

Лабораторная 13. Исследование RAG-чата

Цель работы

Научиться наблюдать за поведением RAG-чата, сопоставлять ответы с материалами базы знаний и находить признаки возможной галлюцинации без сложных инструментов и автоматизации.

Результат работы

- подготовлены и заданы 10 вопросов разных типов
- каждый ответ сопоставлен с материалом базы знаний
- зафиксированы два признака возможной галлюцинации или два подтверждённых ИИ-дефекта
- сформулирован короткий вывод о надёжности ответов RAG-чата

Коротко о RAG и галлюцинациях

RAG-чат сначала ищет подходящие фрагменты в базе знаний, а затем формирует по ним ответ. Поэтому проверяется не красота формулировки, а связь ответа с источником.

Галлюцинация - это правдоподобное утверждение модели, которое не подтверждается доступным источником или прямо ему противоречит. Неточный стиль, короткий ответ, отказ отвечать и отсутствие красивого оформления сами по себе не доказывают галлюцинацию.

1. Подготовьте 10 вопросов

Составьте вопросы заранее. Не задавайте десять одинаковых вопросов с заменой одного слова. Используйте предложенный набор типов.

1	Прямой факт	Факт явно указан в одном документе.
2	ПЕРЕФРАЗИРОВАННЫЙ ВОПРОС	Тот же смысл передан другими словами.
3	Два связанных факта	Ответ требует найти и объединить две части информации.
4	Сравнение	Нужно сравнить два объекта или правила из базы знаний.

5	Уточнение условия	В вопросе не хватает детали, которую чат должен запросить или обозначить.
6	Нет сведений	В базе знаний заведомо нет ответа.
7	Ложная предпосылка	Вопрос содержит утверждение, противоречащее источнику.
8	Опечатка	В ключевом слове допущена понятная опечатка.
9	За пределами темы	Вопрос не относится к KnowBase и выданным материалам.
10	Повторная формулировка	Один из вопросов задан повторно другими словами.

2. Зафиксируйте ожидаемый ответ

До обращения к чату найдите ответ в материалах базы знаний. Запишите ожидаемый факт своими словами и укажите документ или раздел. Для вопросов без ответа запишите: «В базе знаний сведений нет». Такой порядок уменьшает влияние ответа модели на вашу оценку.

3. Задайте вопросы чату

1. Откройте RAG-чат по выданной ссылке.
2. Задавайте вопросы по одному и сохраняйте точную формулировку.
3. Не исправляйте ответ модели и не подсказывайте ей правильный вариант до фиксации результата.
4. Сохраните ответ полностью или сделайте скриншот, если это разрешено преподавателем.
5. Для десятого вопроса переформулируйте один из уже заданных вопросов и сравните смысл ответов.

4. Сопоставьте ответы с источниками

Для каждого ответа выберите один результат оценки.

Подтверждён	Основные утверждения совпадают с источником. Допустимы сокращение и перефразирование.
-------------	---

Подтверждён частично	Часть ответа верна, но важное условие пропущено или добавлено неподтверждённое утверждение.
Не подтверждён	Ключевое утверждение отсутствует в источнике или противоречит ему.
Нельзя оценить	Нет доступа к нужному источнику, стенд не показал ответ или вопрос оказался некорректным.

5. Найдите два признака возможной галлюцинации

Проверьте ответы по следующим признакам. Один ответ может содержать несколько признаков, но в отчёте нужны два разных наблюдения.

- чат уверенно сообщил факт, которого нет в выданных материалах
- ответ противоречит конкретному фрагменту источника
- приведены несуществующая ссылка, раздел, цитата, дата, название или имя
- при отсутствии сведений чат не обозначил ограничение и придумал содержательный ответ
- после перефразирования вопроса ключевой факт изменился без изменения исходных данных
- к правильному факту добавлено существенное условие, которого нет в источнике

Если двух галлюцинаций нет. Не нужно придумывать дефекты. Выберите два наиболее рискованных ответа, опишите, какой признак вы проверяли, и покажите, что источник подтвердил ответ. За честный отрицательный результат балл не снижается.

Форма наблюдений

Таблицу можно перенести в отчёт или заполнить в выданном преподавателем шаблоне.

1				
2				
3				
4				

5				
6				
7				
8				
9				
10				

Для каждого наблюдения укажите номер вопроса, точное спорное утверждение чата, фрагмент или смысл источника, результат сопоставления и короткое объяснение. Формулировка «чат галлюцинировал» без источника и доказательства не принимается.

Пример формулировки. В ответе на вопрос № 6 чат указал срок 30 дней. В разделе 2.4 исходного документа срок не указан. Других подтверждений в выданной базе знаний нет. Это признак возможной галлюцинации, потому что числовой факт добавлен без опоры на источник.

Структура результата

1. ФИО, группа, номер и название лабораторной работы.
2. Таблица с десятью вопросами и результатами сопоставления.
3. Описание двух основных наблюдений.
4. Вывод объемом 4-6 предложений о том, для каких вопросов чат отвечал надёжно, а где требовалась проверка.

Критерии оценивания

Подготовлены и заданы 10 вопросов разных типов.	1 балл
Для всех вопросов зафиксированы ответы и источники проверки.	1,5 балла
Корректно описаны два признака галлюцинации или два проверенных риска.	1,5 балла

Сделан обоснованный вывод, результат понятен и аккуратно оформлен.	1 балл
Итого	5 баллов